

1. Data Warehouse

Kho dữ liệu (Data Warehouse) là một hệ thống quản lý dữ liệu được thiết kế đặc biệt để hỗ trợ quá trình ra quyết định của ban lãnh đạo doanh nghiệp. Đây là nền tảng của mọi dự án phân tích dữ liệu, tập trung vào việc tổ chức, cấu trúc và chuẩn bị dữ liệu để phân tích.

Dựa trên định nghĩa của Bill Inmon (người được coi là cha đẻ của kho dữ liệu), một kho dữ liệu thực thụ có bốn đặc tính cốt lõi sau:

- **Hướng chủ đề (Subject-oriented):** Kho dữ liệu luôn tập trung vào các lĩnh vực kinh doanh cụ thể như bán hàng, khách hàng, tài chính... thay vì tập trung vào các hoạt động vận hành hàng ngày.
- **Tính tích hợp (Integrated):** Nó kết hợp dữ liệu từ nhiều hệ thống nguồn khác nhau vào một nơi duy nhất để có cái nhìn thống nhất.
- **Tính biến đổi theo thời gian (Time-variant):** Kho dữ liệu lưu trữ các dữ liệu lịch sử, cho phép doanh nghiệp phân tích các xu hướng và thay đổi qua các thời kỳ.
- **Tính bất biến (Non-volatile):** Một khi dữ liệu đã được nạp vào kho, nó sẽ không bị xóa hoặc sửa đổi, đảm bảo tính ổn định cho việc báo cáo.

Về mặt vai trò, kho dữ liệu đóng vai trò là **"Điểm tin cậy duy nhất" (Single point of truth)** cho việc báo cáo và phân tích. Thay vì mỗi phòng ban sử dụng một báo cáo thủ công riêng lẻ, tất cả đều truy xuất từ một nguồn dữ liệu đã được làm sạch và chuẩn hóa.

Để dễ hình dung, nguồn tài liệu so sánh kho dữ liệu như **khu bếp của một nhà hàng bận rộn**. Các nguyên liệu thô (dữ liệu nguồn) được đưa đến, sau đó được làm sạch, sơ chế và sắp xếp ngăn nắp trong kho hoặc tủ lạnh (giai đoạn chuẩn bị). Khi có yêu cầu (báo cáo hoặc phân tích), các nguyên liệu đã chuẩn bị sẵn này sẽ nhanh chóng được chế biến thành một "món ăn hoàn hảo" để phục vụ khách hàng. Quy trình này thường được thực hiện thông qua hệ thống **ETL** (Trích xuất, Biến đổi, Nạp) để tự động hóa và đảm bảo tốc độ cũng như độ chính xác cao.

2. Kho dữ liệu trong mối tương quan với các loại kiến trúc khác và các phương pháp triển khai cụ thể

2.1. Vị trí của Kho dữ liệu trong các loại kiến trúc dữ liệu

Nguồn tài liệu phân loại bốn hướng tiếp cận chính trong quản lý dữ liệu hiện đại:

- **Kho dữ liệu (Data Warehouse):** Phù hợp nhất khi doanh nghiệp chủ yếu làm việc với **dữ liệu có cấu trúc** và muốn xây dựng một nền tảng vững chắc cho báo cáo và trí tuệ doanh nghiệp (BI).
- **Hồ dữ liệu (Data Lake):** Linh hoạt hơn kho dữ liệu vì có thể lưu trữ cả dữ liệu có cấu trúc, bán cấu trúc và phi cấu trúc (như hình ảnh, video, log). Nó phục vụ tốt cho phân tích nâng cao và học máy, nhưng nếu không được tổ chức tốt, nó có thể biến thành "đầm lầy dữ liệu" (data swamp).
- **Data Lakehouse:** Là sự kết hợp giữa Kho dữ liệu và Hồ dữ liệu. Nó mang lại sự linh hoạt của Hồ dữ liệu nhưng vẫn giữ được cấu trúc và khả năng tổ chức của Kho dữ liệu. Đây được coi là phương pháp hiện đại và là xu hướng được ưa chuộng hiện nay.
- **Lưới dữ liệu (Data Mesh):** Khác với ba loại trên (vốn mang tính tập trung), Data Mesh là cách tiếp cận **phi tập trung**. Thay vì một hệ thống quản lý trung tâm duy nhất, mỗi bộ phận hoặc miền kinh doanh sẽ tự xây dựng và chia sẻ "sản phẩm dữ liệu" của riêng mình để tránh tắc nghẽn.

2.2. Các phương pháp thiết kế nội tại của Kho dữ liệu

Ngay cả khi đã chọn kiến trúc Kho dữ liệu, nguồn tài liệu cũng chỉ ra bốn cách tiếp cận khác nhau để xây dựng nó:

- **Phương pháp Inmon:** Dữ liệu đi qua ba lớp: Staging -> Enterprise Data Warehouse (mô hình hóa theo dạng chuẩn 3 - 3rd Normal Form) -> Data Marts (các tập dữ liệu nhỏ phục vụ báo cáo).
- **Phương pháp Kimball:** Tập trung vào tốc độ bằng cách bỏ qua lớp Kho dữ liệu doanh nghiệp trung tâm để đi thẳng từ Staging tới các Data Marts. Tuy nhiên, điều này có thể dẫn đến sự thiếu nhất quán trong các phép biến đổi dữ liệu về lâu dài.
- **Data Vault:** Tương tự Inmon nhưng mang lại nhiều tiêu chuẩn và quy tắc hơn cho lớp giữa bằng cách chia nó thành "Row Vault" (dữ liệu gốc) và "Business Vault" (dữ liệu áp dụng quy tắc kinh doanh).
- **Kiến trúc Medallion:** Đây là phương pháp được nguồn tài liệu khuyến dùng vì tính dễ hiểu và triển khai. Nó chia kho dữ liệu thành ba lớp: **Bronze** (dữ liệu thô), **Silver** (dữ liệu đã làm sạch) và **Gold** (dữ liệu sẵn sàng cho kinh doanh).

2.3. Bản chất cốt lõi của Kho dữ liệu

Dù theo kiến trúc nào, Kho dữ liệu luôn được định nghĩa bởi bốn đặc tính của Bill Inmon: **hướng chủ đề** (tập trung vào các mảng kinh doanh cụ thể), **tích hợp** (từ nhiều

nguồn), **biến đổi theo thời gian** (lưu lịch sử) và **bất biến** (dữ liệu đã nạp vào thì không xóa/sửa).

Vai trò lớn nhất của nó là trở thành "**Điểm tin cậy duy nhất**" (**Single Point of Truth**), giúp loại bỏ quy trình thủ công chậm chạp, giảm thiểu lỗi con người và đảm bảo toàn bộ doanh nghiệp sử dụng cùng một trạng thái dữ liệu chính xác để ra quyết định

2.4. ETL là gì?

ETL viết tắt của **Extract (Trích xuất)**, **Transform (Biến đổi)** và **Load (Nạp)**. Đây là thành phần cốt lõi của một kho dữ liệu, thường chiếm tới **90% công sức** thực hiện dự án.

- **Extract (Trích xuất):** Là bước xác định và lấy dữ liệu cần thiết từ các hệ thống nguồn mà không làm thay đổi trạng thái gốc của chúng.
- **Transform (Biến đổi):** Giai đoạn nặng nhất, bao gồm việc làm sạch dữ liệu (cleansing), tích hợp (integration), chuẩn hóa (normalization) và định dạng lại dữ liệu để phù hợp với mục đích phân tích.
- **Load (Nạp):** Đưa dữ liệu đã được xử lý vào đích cuối cùng, thường là kho dữ liệu (Data Warehouse).

Quy trình ETL giúp tự động hóa dòng chảy dữ liệu, giảm thiểu sai sót do con người và tạo ra một "**Điểm tin cậy duy nhất**" (**Single Point of Truth**) cho việc lập báo cáo.

2.5. Tài liệu dự án (Project Materials)

Các tài liệu cần thiết để thực hiện dự án bao gồm:

- **Dữ liệu đầu vào:** Các tệp CSV từ hai nguồn hệ thống là **CRM** (thông tin khách hàng, sản phẩm, doanh số) và **ERP** (thông tin khách hàng, vị trí, danh mục sản phẩm).
- **Công cụ kỹ thuật:** SQL Server Express (máy chủ dữ liệu), SQL Server Management Studio - SSMS (giao diện truy vấn), Draw.io (vẽ sơ đồ kiến trúc và dòng chảy dữ liệu).
- **Quản lý dự án và mã nguồn:** Tài khoản **Notion** để lập kế hoạch và **GitHub** để lưu trữ, chia sẻ mã nguồn.

2.6. Kế hoạch dự án bằng Notion (Project Plan Using Notion)

Việc lập kế hoạch rõ ràng là chìa khóa để thành công trong các dự án kho dữ liệu phức tạp. Quy trình xây dựng kế hoạch trên Notion gồm:

- **Tạo bảng Epics:** Liệt kê các giai đoạn lớn như Phân tích yêu cầu, Thiết kế kiến trúc, Khởi tạo dự án.

- **Tạo bảng Tasks:** Chia nhỏ các Epics thành các nhiệm vụ chi tiết (ví dụ: tạo cơ sở dữ liệu, viết script làm sạch dữ liệu).
- **Liên kết dữ liệu:** Sử dụng tính năng **Relation** để kết nối các nhiệm vụ với từng giai đoạn tương ứng.
- **Theo dõi tiến độ:** Sử dụng checkbox để đánh dấu hoàn thành và tính năng **Roll-up** để hiển thị thanh tiến độ (%) cho từng giai đoạn.

2.7. Phân tích yêu cầu (Analyzing Requirements)

Đây là giai đoạn quan trọng nhất (Epic đầu tiên) để hiểu rõ loại kho dữ liệu cần xây dựng, tránh lãng phí thời gian vào những việc không cần thiết. Các yêu cầu cụ thể của dự án này bao gồm:

- **Mục tiêu:** Xây dựng kho dữ liệu hiện đại bằng SQL Server để hợp nhất dữ liệu bán hàng, hỗ trợ báo cáo phân tích và ra quyết định.
- **Nguồn dữ liệu:** Nhập dữ liệu từ hai hệ thống **ERP** và **CRM** dưới dạng tệp CSV.
- **Chất lượng dữ liệu:** Phải làm sạch và khắc phục các vấn đề về chất lượng (dữ liệu thiếu, sai định dạng) trước khi phân tích.
- **Tích hợp:** Kết hợp các nguồn thành một mô hình dữ liệu duy nhất, thân thiện với người dùng.
- **Phạm vi dữ liệu:** Chỉ tập trung vào bộ dữ liệu mới nhất, **không yêu cầu lưu trữ lịch sử (no historization)**.
- **Tài liệu hóa:** Cung cấp tài liệu rõ ràng về mô hình dữ liệu để hỗ trợ người dùng kinh doanh và nhóm phân tích.

3. Thiết kế kiến trúc dữ liệu

3.1. Thiết kế kiến trúc và lựa chọn phương pháp (Choose the Right Approach)

Trước khi xây dựng, bạn cần quyết định loại quản lý dữ liệu và phương pháp thiết kế phù hợp:

- **Các loại kiến trúc dữ liệu lớn:** Có bốn phương pháp tiếp cận chính là **Data Warehouse** (phù hợp với dữ liệu có cấu trúc), **Data Lake** (linh hoạt cho dữ liệu phi cấu trúc), **Data Lakehouse** (kết hợp cả hai) và **Data Mesh** (phi tập trung).
- **Các phương pháp xây dựng Kho dữ liệu (DWH):** Có bốn cách tiếp cận phổ biến gồm **Inmon** (tập trung vào dữ liệu doanh nghiệp tổng thể), **Kimball** (ưu tiên tốc độ xây dựng các Data Mart), **Data Vault** (mang tính tiêu chuẩn hóa cao) và **Medallion Architecture**.

- Lựa chọn tối ưu:** Tài liệu khuyến nghị sử dụng **Kiến trúc Medallion** vì tính đơn giản, dễ hiểu và dễ triển khai.

3.2. Thiết kế các lớp của Kho dữ liệu (Design the Layers of DWH)

Kiến trúc Medallion chia kho dữ liệu thành ba lớp với các đặc tính riêng biệt nhằm tuân thủ nguyên tắc "**Separation of Concerns**" (**Chia tách mối quan tâm**), đảm bảo mỗi lớp có một nhiệm vụ duy nhất và không trùng lặp.

Đặc tính	Lớp Bronze (Đồng)	Lớp Silver (Bạc)	Lớp Gold (Vàng)
Mục tiêu	Lưu trữ dữ liệu thô, nguyên bản để truy vết và sửa lỗi.	Lưu trữ dữ liệu đã được làm sạch và chuẩn hóa.	Cung cấp dữ liệu sẵn sàng cho kinh doanh và phân tích.
Loại đối tượng	Bảng (Table).	Bảng (Table).	View (Bảng ảo) để linh hoạt và không cần nạp dữ liệu.
Phương thức nạp	Full load (Trình tự: Truncate & Insert).	Full load (Trình tự: Truncate & Insert).	Không cần nạp (truy vấn trực tiếp qua View).
Biến đổi dữ liệu	Không chạm vào dữ liệu , giữ nguyên giá trị thiếu, định dạng trạng từ nguồn.	Làm sạch, chuẩn hóa, xử lý dữ liệu.	Áp dụng logic kinh doanh, tích hợp dữ liệu, tổng hợp (aggregation).
Mô hình dữ liệu	Giống hệ thống nguồn.	Giống hệ thống nguồn.	Star Schema (Sơ đồ hình sao) hoặc Snowflake.
Người dùng	Chỉ dành cho kỹ sư dữ liệu (Data Engineer).	Kỹ sư dữ liệu, Nhà phân tích (Data Analyst/Scientist).	Nhà phân tích và người dùng kinh doanh (Business Users).

3.3. Vẽ sơ đồ kiến trúc bằng Draw.io (Draw the Architecture)

Việc trực quan hóa kiến trúc giúp các bên liên quan hiểu rõ dòng chảy dữ liệu. Quy trình thực hiện như sau:

- Tạo các khung chứa chính (Containers):** Vẽ ba khung lớn đại diện cho **Sources** (Nguồn), **Data Warehouse** (Kho dữ liệu) và **Consume** (Tiêu thụ).
- Thiết lập các lớp bên trong DWH:** Bên trong khung Data Warehouse, vẽ ba khung nhỏ hơn cho **Bronze**, **Silver** và **Gold**. Sử dụng màu sắc khác nhau để phân biệt (ví dụ: vàng cho lớp Gold, xám cho Silver).

- **Thêm chi tiết kỹ thuật:**
 - Ở khung **Sources**: Sử dụng các icon như thư mục hoặc file (nếu nguồn là CSV) và liệt kê các hệ thống nguồn (ví dụ: CRM, ERP).
 - Ở khung **DWH**: Thêm icon cơ sở dữ liệu và các thông tin mô tả bên dưới mỗi lớp như: loại đối tượng (Table/View), phương thức nạp (Full load), và các loại biến đổi (Cleansing/Business logic).
 - Ở khung **Consume**: Liệt kê các công cụ hoặc mục đích sử dụng như Power BI, Tableau, SQL queries hoặc Machine Learning.
- **Vẽ dòng chảy dữ liệu**: Sử dụng các mũi tên để kết nối từ Nguồn qua các lớp Bronze, Silver đến Gold và cuối cùng là người tiêu dùng.
- **Công cụ và Kỹ thuật**: Sử dụng icon từ các trang như Flat Icon và thêm logo của công nghệ sử dụng (ví dụ: **SQL Server**) để sơ đồ chuyên nghiệp hơn.

4. Các bước khởi tạo dự án

4.1. Khởi tạo dự án (Project Initialization)

Việc lập kế hoạch là chìa khóa để thành công vì hơn 50% dự án kho dữ liệu thất bại do thiếu kế hoạch rõ ràng.

- **Công cụ**: Sử dụng **Notion** để quản lý ý tưởng, nguồn lực và kế hoạch dự án.
- **Thiết lập bảng Epics**: Tạo một bảng chứa các giai đoạn lớn (ví dụ: Requirements Analysis, Design Architecture, Project Initialization).
- **Thiết lập bảng Tasks**: Tạo các nhiệm vụ nhỏ và sử dụng tính năng **Relation** trong Notion để liên kết chúng với các Epics tương ứng.
- **Theo dõi tiến độ**: Sử dụng tính năng **Roll-up** và hộp kiểm (checkbox) để tạo thanh tiến độ (progress bar) tự động cho từng giai đoạn.

4.2. Xác định quy tắc đặt tên (Define Naming Conventions)

Quy tắc đặt tên cần được thiết lập sớm để tránh sự hỗn loạn khi có nhiều nhà phát triển cùng tham gia.

- **Định dạng chung**: Sử dụng **snake_case** (tất cả chữ thường, ngăn cách bằng dấu gạch dưới) và tránh dùng các từ khóa dự phòng của SQL.
- **Lớp Bronze & Silver**: Tên bảng theo cấu trúc TênHệThốngNguồn_TênThựcThể (ví dụ: crm_cust_info).
- **Lớp Gold**: Tên bảng theo cấu trúc Loại_TênThựcThể (ví dụ: dim_customers, fact_sales).

- **Cột dữ liệu:** Các khóa thay thế (surrogate keys) kết thúc bằng `_key`. Các cột kỹ thuật/metadata bắt đầu bằng tiền tố `dw_` (ví dụ: `dw_load_date`).
- **Stored Procedures:** Bắt đầu bằng `load_` kèm tên lớp (ví dụ: `load_bronze`).

4.3. Chuẩn bị kho lưu trữ GIT (Prepare Your GIT Repository)

GIT giúp theo dõi mã nguồn, cộng tác nhóm và xây dựng hồ sơ năng lực (portfolio) chuyên nghiệp,.

- **Khởi tạo:** Tạo kho lưu trữ mới (nên để Public nếu làm portfolio), thêm tệp README và chọn giấy phép MIT.
- **Cấu trúc thư mục:** Thiết lập các thư mục chính bao gồm: datasets (dữ liệu mẫu), docs (tài liệu), scripts (mã SQL) và tests (kịch bản kiểm tra),.
- **Tệp README:** Viết mô tả dự án, yêu cầu và thông tin liên hệ bằng định dạng Markdown,.

4.4. Tạo cơ sở dữ liệu & Lược đồ (Create Database & Schemas)

Sử dụng SQL Server Management Studio (SSMS) để triển khai cấu trúc kho dữ liệu,.

- **Tạo Database:** Sử dụng lệnh `CREATE DATABASE DataWarehouse`.
- **Tạo Schemas:** Tạo 3 lược đồ tương ứng với kiến trúc Medallion: bronze, silver, và gold để tổ chức dữ liệu theo lớp,.
- **Lưu ý kỹ thuật:** Sử dụng lệnh `GO` giữa các câu lệnh để đảm bảo SQL Server thực thi tuần tự.

4.5. Commit mã nguồn vào Git (Commit Code in Git Repo)

Sau khi viết các kịch bản SQL (ví dụ: `init_database.sql`), bạn cần lưu trữ chúng vào thư mục scripts trong Git.

- **Header Comment:** Luôn thêm chú thích ở đầu mỗi script để giải thích mục đích, tác giả và các **cảnh báo quan trọng** (ví dụ: cảnh báo script này sẽ xóa sạch dữ liệu nếu chạy lại),.
- **Quy trình:** Việc commit thường xuyên giúp bạn có thể khôi phục lại các phiên bản cũ nếu có sai sót xảy ra trong quá trình phát triển,

5. Xây dựng Lớp Bronze

Việc xây dựng **lớp Bronze** (lớp Đồng) là giai đoạn đầu tiên trong quy trình kỹ thuật dữ liệu, tập trung vào việc trích xuất và nạp dữ liệu thô vào kho dữ liệu mà không làm thay đổi trạng thái gốc của chúng

5.1. Phân tích hệ thống nguồn (Analyze Source Systems)

Trước khi viết mã, bạn cần thực hiện một cuộc phỏng vấn hoặc tìm hiểu kỹ với các chuyên gia hệ thống nguồn để hiểu bản chất của dữ liệu,. Các khía cạnh cần làm rõ bao gồm:

- **Bối cảnh nghiệp vụ:** Ai sở hữu dữ liệu và dữ liệu này hỗ trợ quy trình nào (bán hàng, nhân sự, hay tài chính).
- **Tài liệu kỹ thuật:** Tìm hiểu về mô hình dữ liệu (ERD), từ điển dữ liệu (Data Catalog) và các công nghệ lưu trữ (On-premise hay Cloud),.
- **Phương thức tích hợp:** Xác định cách trích xuất dữ liệu (qua API, kết nối trực tiếp cơ sở dữ liệu hay qua tệp tin CSV) và tần suất nạp (nạp toàn bộ - Full load hay nạp gia tăng - Incremental),.
- **Hạn chế hệ thống:** Hiểu về các giới hạn hiệu suất, quyền truy cập (Tokens, Passwords) và khối lượng dữ liệu dự kiến để tránh làm chậm hệ thống nguồn khi trích xuất,.

5.2. Tạo DDL cho các bảng (Create DDL for Tables)

Sau khi hiểu cấu trúc dữ liệu từ nguồn, bạn cần tạo các bảng trong lược đồ bronze để lưu trữ dữ liệu này,.

- **Quy tắc đặt tên:** Sử dụng định dạng bronze.<tên_hệ_thống>_<tên_thực_thể> (ví dụ: bronze.crm_cust_info) để dễ dàng nhận diện nguồn gốc,.
- **Cấu trúc bảng:** Các cột trong lớp Bronze phải được giữ **nguyên trạng 1:1** so với hệ thống nguồn về cả tên gọi và kiểu dữ liệu,.
- **Logic khởi tạo:** Sử dụng câu lệnh IF OBJECT_ID ... IS NOT NULL DROP TABLE trước khi CREATE TABLE để cho phép chạy lại script mà không gặp lỗi bảng đã tồn tại,.

5.3. Phát triển Script nạp SQL (Develop SQL Load Scripts)

Dự án sử dụng phương thức **BULK INSERT** để nạp dữ liệu từ các tệp CSV vào SQL Server vì tốc độ xử lý nhanh chóng cho khối lượng lớn.

- **Cấu hình nạp:** Cần chỉ định đường dẫn tệp tin và các tham số như FIRSTROW = 2 (để bỏ qua dòng tiêu đề) và FIELDTERMINATOR = ',' (xác định dấu phẩy là ký tự ngăn cách các cột),.
- **Chiến lược nạp toàn bộ (Full Load):** Sử dụng lệnh TRUNCATE TABLE trước khi thực hiện BULK INSERT để làm trống bảng cũ và nạp lại toàn bộ dữ liệu mới, tránh tình trạng trùng lặp dữ liệu,.

5.4. Tạo Stored Procedure (Create Stored Procedure)

Để tự động hóa quy trình nạp dữ liệu lớp Bronze, tất cả các script nạp nên được đóng gói vào một **Stored Procedure** (thủ tục lưu trữ) mang tên load_bronze,. Một thủ tục chuyên nghiệp cần tích hợp các thành phần sau:

- **Thông báo (Messaging):** Sử dụng lệnh PRINT để hiển thị tiến độ (ví dụ: "Đang làm trống bảng...", "Đang nạp dữ liệu vào bảng...") giúp việc theo dõi và gỡ lỗi dễ dàng hơn,.
- **Xử lý lỗi (Error Handling):** Bọc mã nguồn trong khối BEGIN TRY...END TRY và BEGIN CATCH...END CATCH để bắt các lỗi SQL và hiển thị thông tin lỗi (số lỗi, thông báo lỗi) thay vì làm dừng hệ thống đột ngột,.
- **Đo lường hiệu suất:** Khai báo các biến start_time và end_time, sử dụng hàm GETDATE() và DATEDIFF để tính toán chính xác thời gian thực thi (duration) cho từng bảng và toàn bộ quy trình nạp,.

5.5. Tài liệu hóa: Dòng chảy dữ liệu (Document: Data Flow)

Cuối cùng, bạn cần vẽ sơ đồ dòng chảy dữ liệu (Data Flow Diagram) để trực quan hóa quy trình.

- **Mục tiêu:** Tạo ra **Data Lineage** (truy vết dữ liệu), giúp hiểu rõ một bảng ở lớp Bronze tương ứng với tệp tin nào ở hệ thống nguồn (CRM hay ERP),.
- **Thực hiện:** Sử dụng các công cụ như Draw.io để vẽ các mũi tên kết nối từ các tệp nguồn đến các bảng tương ứng trong lớp Bronze. Điều này cực kỳ hữu ích khi cần phân tích nguyên nhân gốc rễ nếu dữ liệu gặp sự cố sau này,.

6. Xây dựng lớp Silver

Việc xây dựng **lớp Silver (Lớp Bạc)** là giai đoạn quan trọng nhất trong quy trình kỹ thuật dữ liệu, nơi dữ liệu thô từ lớp Bronze được làm sạch, chuẩn hóa và định dạng lại để sẵn sàng cho phân tích

6.1. Khám phá và hiểu dữ liệu (Explore & Understand Data)

Trước khi làm sạch, bạn cần thực hiện **thăm dò dữ liệu (Data Exploration)** để phát hiện các vấn đề về chất lượng và hiểu mối quan hệ giữa các bảng.

- Sử dụng lệnh SELECT TOP 1000 để xem nhanh nội dung mà không làm quá tải hệ thống.
- Xác định các khóa chính (Primary Keys), kiểm tra giá trị Null và các bản ghi trùng lặp.

- **Vẽ Sơ đồ tích hợp dữ liệu** để hình dung cách kết nối các bảng từ các hệ thống khác nhau (ví dụ: kết nối CRM và ERP qua mã khách hàng).

6.2. Tạo DDL cho các bảng (Create DDL for Tables)

Cấu trúc bảng ở lớp Silver về cơ bản giống hệt lớp Bronze để đảm bảo tính nhất quán.

- **Quy tắc:** Sao chép kịch bản DDL từ lớp Bronze và thay đổi schema thành silver.
- **Thêm cột Metadata:** Mỗi bảng trong lớp Silver nên có thêm cột kỹ thuật như `dw_create_date` (sử dụng kiểu `datetime2` và giá trị mặc định là `GETDATE()`) để phục vụ mục đích kiểm toán và truy vết thời gian nạp dữ liệu.

6.3. Làm sạch và nạp dữ liệu chi tiết (Clean & Load)

Quy trình nạp cho mỗi bảng tuân theo chiến lược **Full Load**: Xóa dữ liệu cũ (TRUNCATE) và nạp dữ liệu đã làm sạch (INSERT).

crm_cust_info

- **Loại bỏ trùng lặp:** Sử dụng hàm `ROW_NUMBER()` kết hợp với `PARTITION BY` mã khách hàng và `ORDER BY` ngày tạo để chỉ lấy bản ghi mới nhất.
- **Xử lý văn bản:** Dùng hàm `TRIM()` để xóa khoảng trắng thừa ở cột tên.
- **Chuẩn hóa:** Chuyển đổi các chữ cái viết tắt (M, F, S) thành tên đầy đủ (Male, Female, Single) bằng câu lệnh `CASE WHEN`.

crm_prd_info

- **Tách cột:** Sử dụng `SUBSTRING` để tách `product_key` thành `category_id` và mã sản phẩm.
- **Xử lý giá trị thiếu:** Thay thế giá trị Null ở cột giá bằng 0 bằng hàm `ISNULL`.
- **Sửa lỗi lịch sử:** Sử dụng hàm `LEAD()` để tính toán lại ngày kết thúc (`end_date`) của sản phẩm, đảm bảo không có sự chồng chéo về thời gian giữa các phiên bản giá.

crm_sales_details

- **Chuyển đổi kiểu dữ liệu:** Chuyển các cột ngày tháng từ kiểu số (Integer) sang kiểu ngày thực thụ (DATE).
- **Áp dụng quy tắc kinh doanh:** Kiểm tra và tính toán lại doanh số nếu `sales != quantity * price`. Đảm bảo các giá trị âm hoặc Null được xử lý theo logic nghiệp vụ.

erp_cust_az12

- **Làm sạch mã khách hàng:** Loại bỏ tiền tố "NAS" không cần thiết bằng hàm SUBSTRING để có thể khớp với dữ liệu từ CRM.
- **Hợp lệ hóa ngày sinh:** Chuyển các ngày sinh ở tương lai về giá trị Null.

erp_loc_a101

- **Chuẩn hóa mã ID:** Xóa dấu gạch ngang trong mã khách hàng bằng hàm REPLACE.
- **Chuẩn hóa quốc gia:** Hợp nhất các tên quốc gia viết tắt hoặc sai định dạng (ví dụ: 'DE', 'USA', 'US') thành tên chuẩn (Germany, United States).

erp_px_cat_g1v2

- Bảng này thường có chất lượng tốt, chỉ cần nạp trực tiếp vào lớp Silver sau khi kiểm tra các khoảng trống thừa.

6.4. Tạo thủ tục lưu trữ (Create Stored Procedure)

Để tự động hóa, toàn bộ mã nạp lớp Silver được đóng gói vào một **Stored Procedure** tên là `silver.load_silver`.

- **Cấu trúc chuyên nghiệp:** Sử dụng khối BEGIN TRY...CATCH để bắt lỗi, in thông báo tiến độ (PRINT) và đo lường thời gian thực thi của từng bảng bằng các biến `start_time`, `end_time`.
- **Kiểm soát:** Thủ tục này đảm bảo dữ liệu được làm sạch đồng bộ mỗi khi chạy.

6.5. Tài liệu hóa: Dòng chảy dữ liệu (Document: Data Flow)

Cuối cùng, cập nhật sơ đồ dòng chảy dữ liệu bằng Draw.io để thể hiện sự kết nối giữa lớp Bronze và Silver.

- Việc vẽ **Data Lineage** (Truy vết dữ liệu) giúp bạn dễ dàng xác định nguồn gốc của dữ liệu khi xảy ra lỗi ở các lớp cao hơn.
- Mỗi mũi tên sẽ chỉ rõ bảng nào ở lớp Silver được nạp từ bảng nào ở lớp Bronze, tạo thành một hệ thống tài liệu trực quan cho nhóm phát triển

7. Xây dựng lớp Gold

Việc xây dựng **Lớp Vàng (Gold Layer)** là giai đoạn cuối cùng và quan trọng nhất trong kiến trúc Medallion, nơi dữ liệu được chuyển đổi thành các đối tượng sẵn sàng cho kinh doanh phục vụ báo cáo và phân tích

7.1. Mô hình hóa dữ liệu (Data Modeling)

Mô hình hóa dữ liệu là quá trình tổ chức và cấu trúc dữ liệu thô thành các đối tượng có ý nghĩa (như khách hàng, đơn hàng, sản phẩm) và xác định mối quan hệ giữa chúng. Quy trình này thường đi qua ba giai đoạn:

- **Conceptual (Khái niệm):** Tập trung vào các thực thể chính và mối quan hệ tổng quát, không đi sâu vào chi tiết cột.
- **Logical (Logic):** Xác định chi tiết các cột/thuộc tính trong từng thực thể.
- **Physical (Vật lý):** Chuẩn bị đầy đủ các chi tiết kỹ thuật như kiểu dữ liệu và độ dài để triển khai trong cơ sở dữ liệu.

7.2. Sơ đồ hình sao (Star Schema) vs. Sơ đồ bông tuyết (Snowflake Schema)

Để tối ưu cho phân tích, dự án sử dụng **Star Schema** thay vì Snowflake Schema.

- **Star Schema:** Gồm một bảng **Fact** ở trung tâm, bao quanh bởi các bảng **Dimension**. Ưu điểm là dễ hiểu, dễ truy vấn và tối ưu cho các công cụ báo cáo như Power BI,.
- **Snowflake Schema:** Tương tự sơ đồ hình sao nhưng các Dimension được chuẩn hóa thêm (chia nhỏ). Điều này giúp tiết kiệm bộ nhớ nhưng làm tăng độ phức tạp khi truy vấn.

7.3. Bảng Chiều (Dimensions) vs. Bảng Sự kiện (Facts)

- **Dimensions (Chiều):** Chứa thông tin mô tả về đối tượng (trả lời câu hỏi: Ai? Cái gì? Ở đâu?).
- **Facts (Sự kiện):** Chứa các giao dịch hoặc sự kiện thực tế, bao gồm các ID để kết nối với Dimension và các chỉ số đo lường (trả lời câu hỏi: Bao nhiêu?).

7.4. Khám phá các đối tượng kinh doanh (Business Objects)

Từ 6 bảng dữ liệu ở hệ thống nguồn (CRM và ERP), dự án xác định được 3 đối tượng kinh doanh chính:

- **Products (Sản phẩm):** Tích hợp thông tin sản phẩm và danh mục sản phẩm.
- **Customers (Khách hàng):** Tích hợp thông tin cá nhân, ngày sinh và vị trí từ cả hai hệ thống,.
- **Sales (Bán hàng):** Các bản ghi giao dịch bán hàng.

7.5. Triển khai Lớp Vàng trong SQL

Lớp này được xây dựng dưới dạng **Views** (bảng ảo) để đảm bảo tính linh hoạt và không cần quy trình nạp dữ liệu vật lý,.

- **Tạo Dimension Customers (dim_customers):** Tích hợp từ 3 bảng ở lớp Silver (crm_cust_info, erp_cust_az12, erp_loc_a101) sử dụng **Left Join** để không làm mất dữ liệu khách hàng,.. Dự án áp dụng quy tắc **Master Data**: nếu dữ liệu giới tính tồn tại ở CRM thì ưu tiên sử dụng, nếu không mới lấy từ ERP,.
- **Tạo Dimension Products (dim_products):** Tích hợp từ lớp Silver, thực hiện lọc bỏ dữ liệu lịch sử (chỉ giữ lại bản ghi có end_date IS NULL) để chỉ tập trung vào sản phẩm hiện tại,.
- **Tạo Fact Sales (fact_sales):** Đây là bước thực hiện **Data Lookup**. Các khóa gốc từ hệ thống nguồn được thay thế bằng các **Surrogate Keys** (khóa thay thế) đã tạo ở các bảng Dimension để kết nối mô hình dữ liệu,.
- **Khóa thay thế (Surrogate Keys):** Được tạo bằng hàm ROW_NUMBER() trong SQL để đảm bảo tính duy nhất và quyền kiểm soát dữ liệu trong kho mà không phụ thuộc hoàn toàn vào nguồn,.

7.6. Tài liệu hóa và Quản lý

- **Mô hình sơ đồ hình sao:** Các bảng được kết nối theo quan hệ **1-nhiều** (1 khách hàng/sản phẩm có thể xuất hiện trong nhiều giao dịch bán hàng),.
- **Data Catalog (Danh mục dữ liệu):** Một tài liệu mô tả chi tiết ý nghĩa của từng bảng, từng cột, kiểu dữ liệu và ví dụ minh họa giúp người dùng cuối (nhà phân tích) hiểu và sử dụng dữ liệu hiệu quả mà không cần hỏi kỹ sư dữ liệu,.
- **Data Flow (Dòng chảy dữ liệu):** Sơ đồ này được mở rộng để thể hiện toàn bộ **Data Lineage** (Truy vết dữ liệu) từ Source -> Bronze -> Silver -> Gold, giúp dễ dàng xác định nguồn gốc dữ liệu khi có lỗi xảy ra,.